# Namespace

ภาคการศึกษา 1 2564
กษิดิศ ชาญเชี่ยว
สาขาวิชาวิทยาการคอมพิวเตอร์
คณะวิทยาศาสตร์และเทคโนโลยี
มหาวิทยาลัย ธรรมศาสตร์

เนื้อหาเรียบเรียงจาก https://www.youtube.com/watch?v=0kJPa-1FuoI

# การสร้างภาพเสมือนของระบบลินุกซ์

- ระบบลินุกซ์ประกอบไปด้วยระบบย่อยหลายระบบ
  - ระบบไฟล์
  - ระบบชื่อเครื่อง
  - ระบบเครือข่ายของเครื่อง
  - ระบบจัดการโพรเซส
  - ระบบจัดการการใช้งานทรัพยากร
  - ระบบจัดการผู้ใช้
  - อื่นๆ เช่นระบบจัดการเวลา
- การประมวลผลบนลินุกซ์จัดอยู่ในนามของโพรเซส

# การสร้างภาพเสมือนของระบบลินุกซ์

- ระบบลินุกซ์สามารถสร้างภาพเสมือนของส่วนประกอบย่อย ด้วยเนมสเปซ (Namespace)
  - เนมสเปซมีได้หลายอินสแตนซ์ อินสแต๊นซ์หนึ่งเปรียบเหมือรภาพเสมือนหนึ่ง
- โพรเซสในระบบจะต้องเลือกว่ามันจะรันอยู่ใน เนมสเปซอินสแต๊นซ์ไหนในส่วนประกอบย่อยอันใดอันหนึ่ง
- เนมสเปซ เป็นการจัดกลุ่มของโพรเซส ในเรื่องใดเรื่องหนึ่ง
  - แทนที่จะเป็นกลุ่มเดียว ก็แบ่งแยกออกเป็นหลายกลุ่ม
  - แต่ละกลุ่มมีโลกส่วนตัวของตนเองและโพรเซสคิดว่ากลุ่มของตนเองเป็นผู้ใช้ระบบคอมพิวเตอร์ทั้งหมดไม่สามารถมองเห็นกลุ่มอื่นได้

# เปรียบเทียบกับการลงทะเบียน

- เปรียบเหมือนการเรียนรายวิชาของ นศ --> โพรเซส
- แต่ละรายวิชาเป็นเรื่องย่อยที่อยู่ภายใต้หลักสูตร --> ระบบย่อยของโอเอส
- แต่ละ Section เปรียบเหมือน เนมสเปซอินสแต๊นซ์
- แต่ละวิชามีหลาย sections ที่เป็นภาพเสมือนหลายภาพของวิชาเดียวกัน
- นศ ลงเรียนได้หนึ่ง section เท่านั้น และเห็นเพื่อนใน sec เดียวกันเท่านั้น

| รายวิชา | section | section | section | section |
|---|---|---|---|---|
| TU153 | Sec=1, นาย ก นส ข | Sec=2 | Sec=3 | Sec=5 |
| TU156 | Sec=x1 นส ข | Sec=x2 | Sec=x3 นาย ก | Sec=x4 |
| CS123 | Sec=v1 | Sec=v2 นาย ก | Sec=v12 นส ข | Sec=v5 |
| CS337 | Sec=a นาย ก | Sec=b | Sec=x | Sec=y นส ข |

# เนมสเปซ

- เมื่อระบบลินุกซ์รัน จะมี เนมสเปซ เจ็ดชนิด และลินุกซ์จะสร้างอินสแตนซ์ของเนมสเปซทั้งเจ็ดขึ้น เรียกว่า อินสแตนซ์เริ่มต้น (initial instance)
  - ดังนั้นจะมีเนมสแปซอินสแตนซ์ เจ็ดอินสแตนซ์ แต่ละอันมีชนิดที่ต่างกัน
- สำหรับเนมสเปซแต่ละชนิด โพรเซสจะอยู่ในอินสแตนซ์เดียวเท่านั้น
- โพรเซสที่อยู่ในเนมสเปซอินสแตนซ์ จะนึกว่าตนเองเป็นเจ้าของทรัพยากรที่เกี่ยวข้องกับชนิดของเนมสเปซนั้นทั้งหมด
- โพรเซสที่อยู่ในเนมสเปซอินสแตนซ์เดียวกันจะเห็นกัน และเห็นการเปลี่ยนแปลงทรัพยากรที่โพรเซสอื่นในเนมสเปซอินสแตนซ์เดียวกันทำ
- เมื่อ fork โพรเซสลูกจะอยู่ในเนมสเปซอินสแตนซ์เซ็ตเดียวกันกับโพรเซสพ่อแม่
- โพรเซสจะไม่รู้ว่ามีเนมสเปซอินสแตนซ์อื่นรันอยู่ในระบบ

# ชนิดของเนมสเปซ

- เม้าท์เนมสเปซ (mount namespace)
- ยูทีเอสเนมสเปซ (UTS namespace)
- ไอพีซีเนมสเปซ (IPC namespace)
- พีไอดีเนมสเปซ (PID namespace)
- เน็ตเวิร์คเนมสเปซ (Network namespace)
- ยูเซอร์เนมสเปซ (User namespace)
- ซีกรุ๊ป (Cgroup)
- ไทม์ (Time)

# เนมสเปซ

- เนมสเปซคือการสร้างโลกเสมือนให้กลุ่มของโพรเซสในเรื่องใดเรื่องหนึ่ง
  ต.ย. เม้าท์เนมสแปซ แยกเซตของเม้าท์พ๊อยต์ ให้เห็นเฉพาะกลุ่มของโพรเซสที่อยู่ในเนมสเปซเดียวกัน
- การใช้เนมสเปซมักจะเป็นการใช้เนมสเปซหลายชนิดไปด้วยกัน
  ยกตัวอย่างเช่น แอพพลิเคชั่นหนึ่ง (หรือคอนเทนเนอร์หนึ่ง) อาจกำหนดให้มีกลุ่มของ พีไอดีเนมสเปซ ไอพีซีเนมสเปซ ซีกรุ๊ปเนมสเปซ และเม้าท์เนมสเปซที่ถูกใช้งานไปด้วยกัน
  - ในคอนเทนเนอร์ จะประกอบไปด้วยเซตของเนมสเปซอินสแตนซ์ที่ถูกใช้งานไปด้วยกันเพื่อสร้างภาพเสมือนของคอนเทนเนอร์ที่แยกจากคอนเทนเนอร์อื่น

# ยูทีเอสเนมสเปซ

- ยูทีเอสย่อมาจาก UNIX Time Sharing เป็นเนมสเปซที่อนุญาตให้มีการแยกชื่อเครื่องให้เป็นหลายชื่อได้
- เมื่อใช้คำสั่ง uname ในยูทีเอสเนมสเปซต่างอินสแตนซ์กันจะรีเทิร์น (1) nodename และ (2) nisdomainname ที่แตกต่างกันได้
- คอนเทนเนอร์สามารถใช้ชื่อที่แตกต่างกันเพื่อติอต่อกับ DHCP server เพื่อขอไอพีแอดเดรสแยกกันสำหรับแต่ละคอนเทนเนอร์
- โพรเซสในยูทีเอสเนมสเปซอินสแตนซ์เดียวกันจะเห็นโฮสเนมและโดเมนเนมเดียวกัน การเปลี่ยนแปลงค่าเหล่านี้จะเห็นเฉพาะโพรเซสภายในเนมสเปซเดียวกันเท่านั้น

# ยูทีเอสเนมสเปซ

ยูทีเอส เนมสเปซ เริ่มต้น

initial UTS namespace

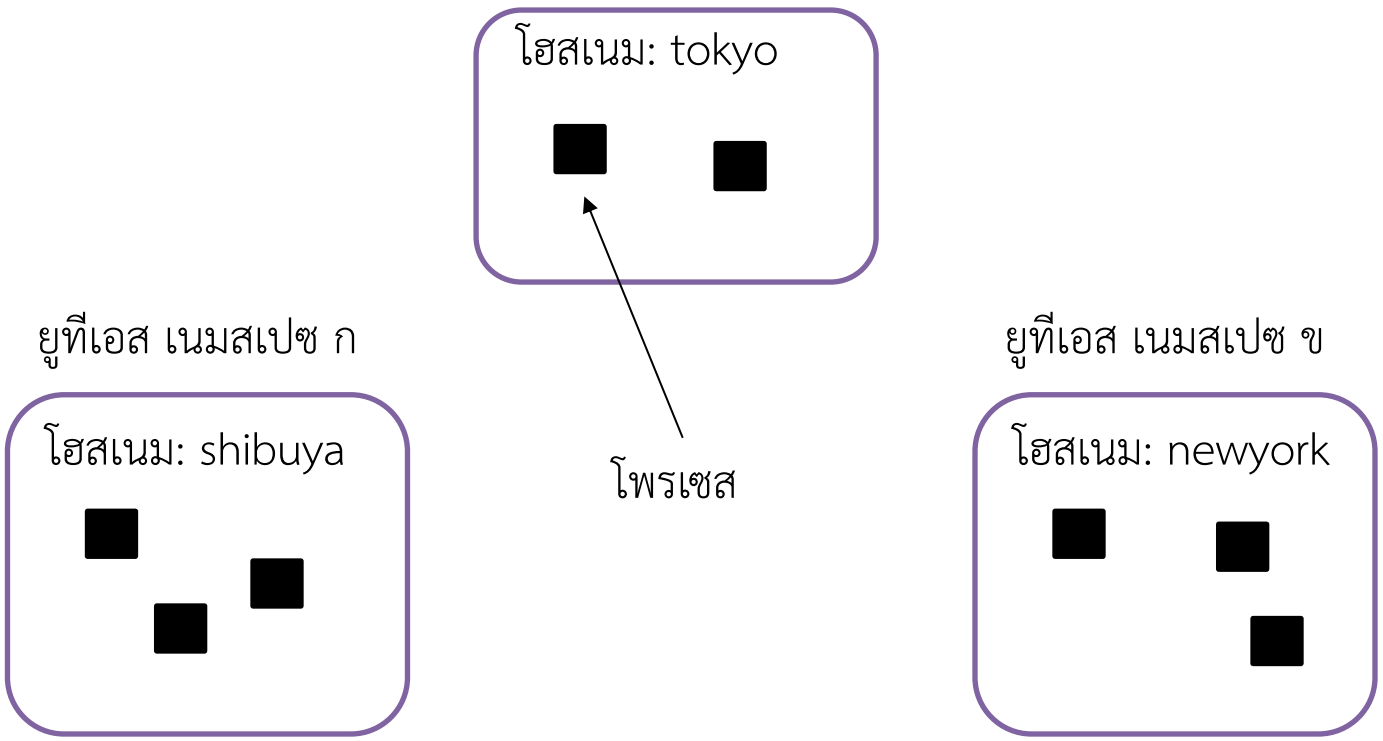

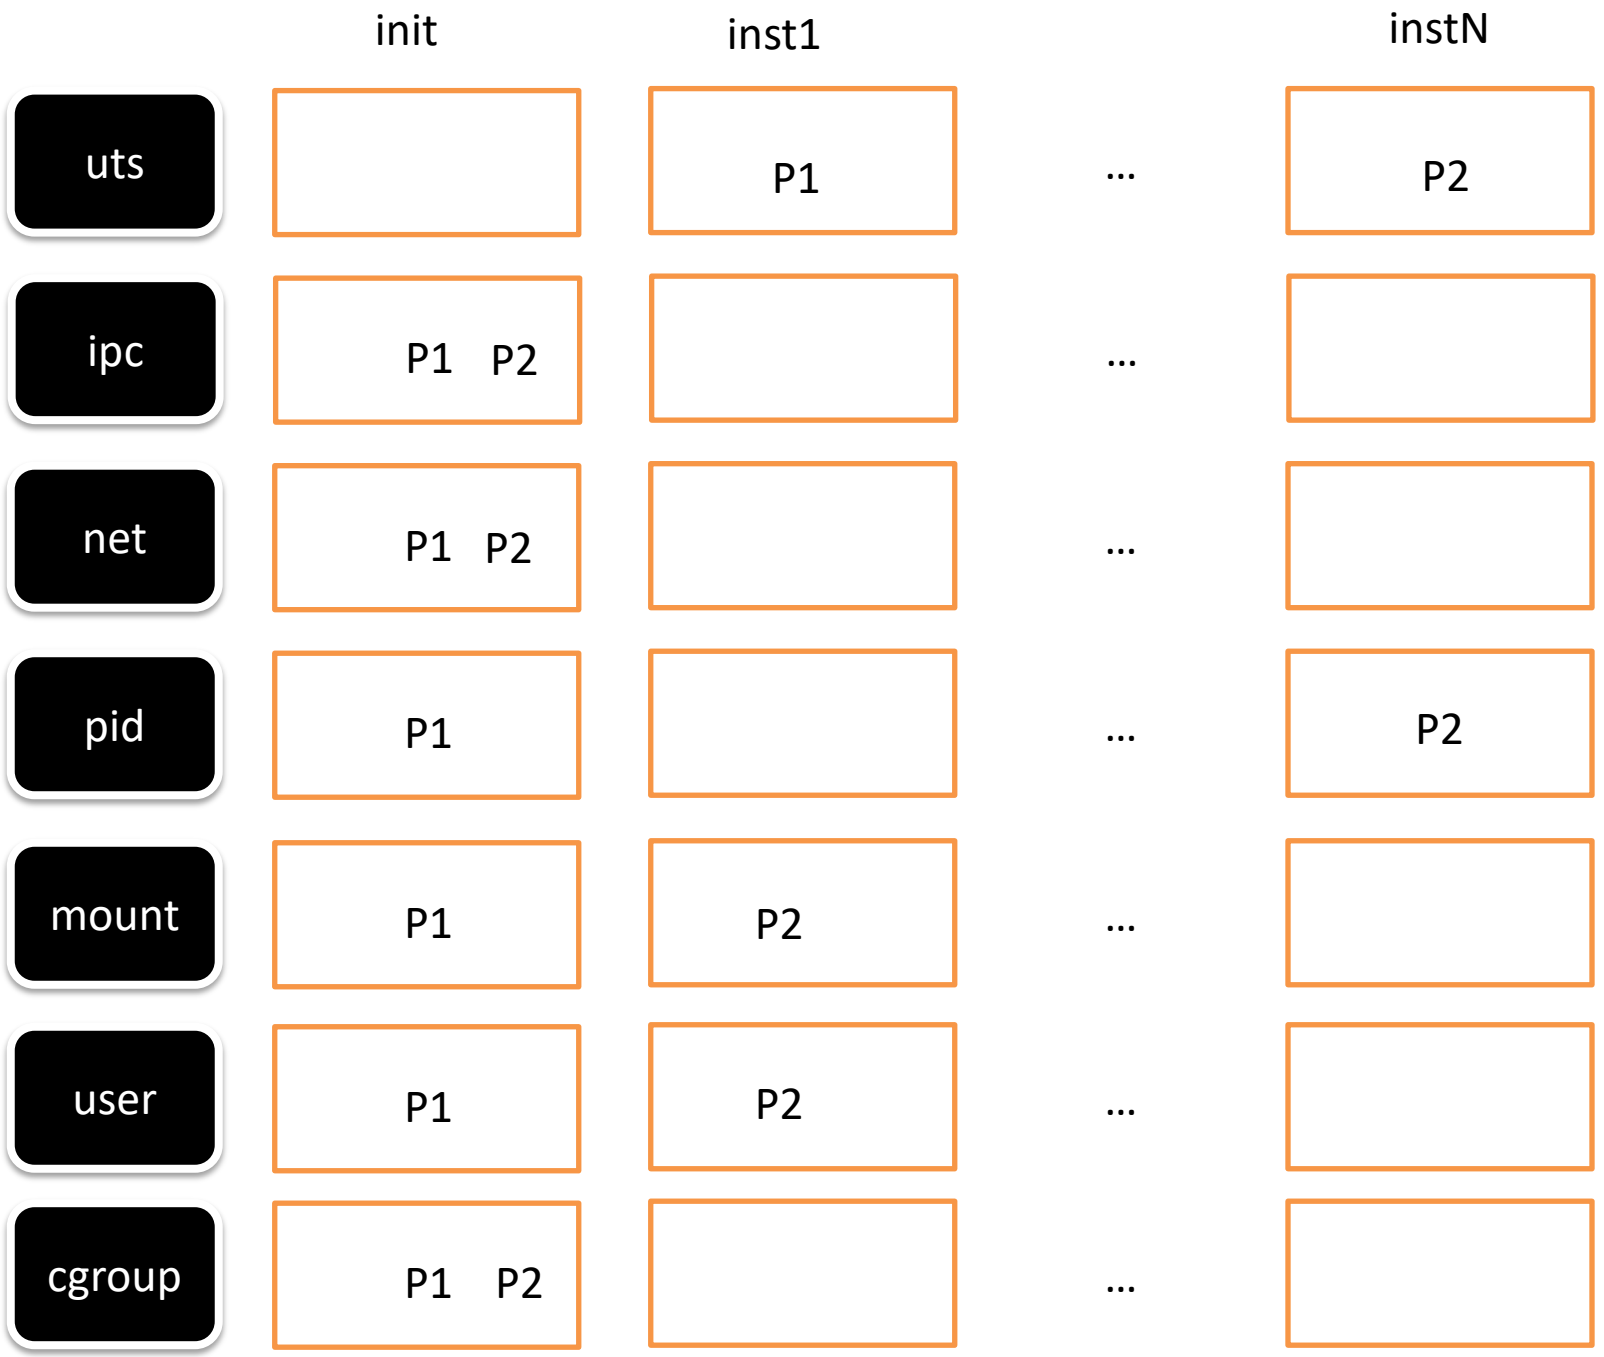
init
inst1
instN
uts
P1
P2
ipc
P1 P2
net
P1 P2
pid
P1
P2
mount
P1
P2
user
P1
P2
cgroup
P1 P2
...

# สร้างโพรเซสและโพรเซสลูก

```
kasidit@flyvm:~$ sh
$
$
$ $$
sh: 3: 3547: not found
$ ps
    PID TTY          TIME CMD
   3536 pts/3    00:00:00 bash
   3547 pts/3    00:00:00 sh
   3548 pts/3    00:00:00 ps
$
$ sh
$
$ $$
sh: 2: 3557: not found
$ ps
    PID TTY          TIME CMD
   3536 pts/3    00:00:00 bash
   3547 pts/3    00:00:00 sh
   3557 pts/3    00:00:00 sh
   3558 pts/3    00:00:00 ps
$
```

# ดูว่าโพรเซสพ่อแม่อยู่ในเนมสเปซอินสแตนซ์ใดบ้าง

- /proc/3547/ns/*
- ตัวเลขใน uts:[4026531838] คือ inode # ในระบบไฟล์ซึ่ง unique

```
$ cd /proc/3547
$ ls -l ns
total 0
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 cgroup -> 'cgroup:[4026531835]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 ipc -> 'ipc:[4026531839]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 mnt -> 'mnt:[4026531840]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 net -> 'net:[4026532000]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 pid -> 'pid:[4026531836]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 pid_for_children -> 'pid:[4026531836]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 user -> 'user:[4026531837]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:04 uts -> 'uts:[4026531838]'
$ readlink /proc/3547/ns/uts
uts:[4026531838]
$
```

# ดูว่า**โพรเซสลูก**อยู่ในเนมสเปซอินสแตนซ์ใดบ้าง

- /proc/3557/ns/*

```
kasidit@flyvm:/proc/3557$ pwd
/proc/3557
kasidit@flyvm:/proc/3557$ ls -l ns
total 0
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 cgroup -> 'cgroup:[4026531835]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 ipc -> 'ipc:[4026531839]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 mnt -> 'mnt:[4026531840]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 net -> 'net:[4026532000]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 pid -> 'pid:[4026531836]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 pid_for_children -> 'pid:[4026531836]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 user -> 'user:[4026531837]'
lrwxrwxrwx 1 kasidit kasidit 0 Oct 10 22:17 uts -> 'uts:[4026531838]'
kasidit@flyvm:/proc/3557$
```

# เอพีไอและคำสั่ง

- ซิสเต็มคอล เอพีไอ ที่เกี่ยวข้องกับเนมสเปซ ได้แก่
  - clone(2) มีออปชั่นให้ สร้างโพรเซสลูกใน เนมสเปซใหม่ได้ และเลือกได้ด้วยว่าเนมสเปซใหม่เป็นชนิดใด
  - unshare(2) สร้างเนมสเปซใหม่ และย้ายโพรเซสที่เรียกใช้ unshare ไปอยู่ในเนมสเปซใหม่นั้น
  - setns(2) ย้ายโพรเซสที่เรียกใช้คำสั่งนี้จากเนมสเปซอินสแตนซ์ปัจจุบันไปอยู่ในอีกอินสแตนซ์หนึ่ง
- คำสั่ง
  - unshare สร้างเนมสเปซและรันคำสั่งในเนมสเปซที่สร้างขึ้น
  - nsenter เข้าสู่เนมสเปซที่มีอยู่แล้วและรันคำสั่งในเนมสเปซนั้น

```
[kasidit@flyvm:/srv/kasidit/study/namespace$ unshare -h

Usage:
 unshare [options] [<program> [<argument>...]]

Run a program with some namespaces unshared from the parent.

Options:
 -m, --mount[=<file>]      unshare mounts namespace
 -u, --uts[=<file>]        unshare UTS namespace (hostname etc)
 -i, --ipc[=<file>]        unshare System V IPC namespace
 -n, --net[=<file>]        unshare network namespace
 -p, --pid[=<file>]        unshare pid namespace
 -U, --user[=<file>]       unshare user namespace
 -C, --cgroup[=<file>]     unshare cgroup namespace

 -f, --fork                fork before launching <program>
 -r, --map-root-user       map current user to root (implies --user)

 --kill-child[=<signame>]  when dying, kill the forked child (implies --fork)
                             defaults to SIGKILL
 --mount-proc[=<dir>]      mount proc filesystem first (implies --mount)
 --propagation slave|shared|private|unchanged
                           modify mount propagation in mount namespace
 --setgroups allow|deny    control the setgroups syscall in user namespaces

 -R, --root=<dir>           run the command with root directory set to <dir>
 -w, --wd=<dir>     change working directory to <dir>
 -S, --setuid <uid>         set uid in entered namespace
 -G, --setgid <gid>         set gid in entered namespace
```

```
kasidit@flyvm:/srv/kasidit/study/namespace$ nsenter -h

Usage:
 nsenter [options] [<program> [<argument>...]]

Run a program with namespaces of other processes.

Options:
 -a, --all              enter all namespaces
 -t, --target <pid>     target process to get namespaces from
 -m, --mount[=<file>]   enter mount namespace
 -u, --uts[=<file>]     enter UTS namespace (hostname etc)
 -i, --ipc[=<file>]     enter System V IPC namespace
 -n, --net[=<file>]     enter network namespace
 -p, --pid[=<file>]     enter pid namespace
 -C, --cgroup[=<file>]  enter cgroup namespace
 -U, --user[=<file>]    enter user namespace
 -S, --setuid <uid>     set uid in entered namespace
 -G, --setgid <gid>     set gid in entered namespace
     --preserve-credentials do not touch uids or gids
 -r, --root[=<dir>]     set the root directory
 -w, --wd[=<dir>]       set the working directory
 -F, --no-fork          do not fork before exec'ing <program>
 -Z, --follow-context   set SELinux context according to --target PID

 -h, --help             display this help
 -V, --version          display version

For more details see nsenter(1).
```

# สิทธิ์ในการสร้างเนมสเปซ

- ถ้าสร้างอินสแตนซ์ของ ยูเซอร์เนมสเปซ ไม่ต้องใช้สิทธิ์พิเศษใด
- ถ้าสร้างอินสแตนซ์ของเนมสเปซแบบอื่น บัญชีผู้ใช้ของผู้สร้างต้องมี CAP_SYS_ADMIN

```
kasidit@flyvm:/srv/kasidit/study/namespace$ readlink /proc/$$/ns/uts
uts:[4026531838]
kasidit@flyvm:/srv/kasidit/study/namespace$ echo $$
3630
kasidit@flyvm:/srv/kasidit/study/namespace$ sudo unshare -u bash
root@flyvm:/srv/kasidit/study/namespace# echo $$
3715
root@flyvm:/srv/kasidit/study/namespace# readlink /proc/$$/ns/uts
uts:[4026532461]
root@flyvm:/srv/kasidit/study/namespace# hostname tokyo
root@flyvm:/srv/kasidit/study/namespace# hostname
tokyo
root@flyvm:/srv/kasidit/study/namespace#

  0 bash
kasidit@flyvm:/srv/kasidit/study/namespace$ readlink /proc/$$/ns/uts
uts:[4026531838]
kasidit@flyvm:/srv/kasidit/study/namespace$ echo $$
3640
kasidit@flyvm:/srv/kasidit/study/namespace$ hostname
flyvm
kasidit@flyvm:/srv/kasidit/study/namespace$ hostname
flyvm
kasidit@flyvm:/srv/kasidit/study/namespace$
```

```
root@flyvm:/srv/kasidit/study/namespace# readlink /proc/$$/ns/mnt
mnt:[4026531840]
root@flyvm:/srv/kasidit/study/namespace# echo $$
3715
root@flyvm:/srv/kasidit/study/namespace# hostname
tokyo
root@flyvm:/srv/kasidit/study/namespace# readlink /proc/$$/ns/uts
uts:[4026532461]
root@flyvm:/srv/kasidit/study/namespace#
```

```
  0 bash
kasidit@flyvm:/srv/kasidit/study/namespace$ readlink /proc/$$/ns/mnt
mnt:[4026531840]
kasidit@flyvm:/srv/kasidit/study/namespace$ sudo nsenter -t 3715 -u bash
root@tokyo:/srv/kasidit/study/namespace#
root@tokyo:/srv/kasidit/study/namespace# readlink /proc/$$/ns/uts
uts:[4026532461]
root@tokyo:/srv/kasidit/study/namespace# hostname
tokyo
root@tokyo:/srv/kasidit/study/namespace#
```

# เนมสเปซ และ คอนเทนเนอร์

- เราใช้เนมสเปซสร้าง คอนเทนเนอร์ (container) หรือ การประมวลผลแบบเสมือนที่มีโอเวอร์เฮดน้อย (light-weighted virtualization)
- เป็นการสร้างภาพเสมือนของระบบคอมพิวเตอร์โดยการแยกกลุ่มของโพรเซส และให้โพรเซสกลุ่มนั้นคิดว่ากลุ่มของตนครอบครองทั้งระบบ
- การประมวลผลแบบเสมือนตามปกติจะแยกเกสโอเอสอย่างชัดเจนและแต่ละเกสวีเอ็มก็มีโพรเซสของมัน
  - เกสโอเอสอาจต่างชนิด (ต่างเคอร์เนิล) กัน
  - มีการรักษาความปลอดภัยของเกสโอเอสแต่ละอัน
  - แต่ใช้เวลาในการรันวีเอ็มเนื่องจากเกสใช้เวลารันนาน (ยกเว้น unikernel)
- แต่การแยกกันโดยใช้เนมสเปซเป็นการแยกกันแบบที่แต่ละกลุ่มของโปรเซสถึงแม้จะไม่เห็นกันแชร์โอเอสเคอร์เนิลเดียวกัน

# เนมสเปซ และ คอนเทนเนอร์

- การใช้เนมสเปซมีโอเวอร์เฮดน้อยกว่าวีเอ็ม ดังนั้นจึงเริ่มต้นการประมวลผลได้เร็วกว่า
- มีความละเอียดในการกำหนดลักษณะของการแยกกันที่ละเอียดกว่า เพราะผู้ใช้สามารถเลือกได้ว่าจะแยกหรือไม่แยกเนมสเปซอินสแตนซ์ชนิดใด
- แต่ในการสร้างคอนเทนเนอร์จะต้องกำหนดรายละเอียดมากตามไปด้วย เพราะคอนเทนเนอร์หนึ่งเกี่ยวข้องกับเนมสเปซหลายแบบ และเคอร์เนิลต้องมีความสามารถสนับสนุนการแยกและสร้างภาพเสมือนด้วยเนมสแปซเป็นอย่างดี และมีความซับซ้อนมาก (ใช้เวลาในการพัฒนามาก)
  - ต.ย. เนมสเปซล่าสุด ไทม์เนมสเปซ ได้ถูกเสนอมาตั้งแต่ 2018 เพิ่งอยู่ใน mainline linux kernel ในปี 2020

# เนมสเปซ และ คอนเทนเนอร์

- เนมสเปซ จะเป็นตัวกำหนดว่ากลุ่มของโพรเซสในคอนเทนเนอร์จะเห็นอะไรในระบบได้บ้าง
- ปกติแล้วเมื่อโพรเซสสุดท้านในเนมสเปซจบการประมวลผล รนมสเปซจะถูกทำลาย แต่ผู้ใช้สามารถใช้วิธีการ mount-binding เพื่อเก็บไฟล์ psudo-file ของเนมสเปซนั้น เพื่อไม่ให้ถูกทำลายและนำมาใช้ภายหลังได้
- ซีกรุ๊ป จะเป็นตัวกำหนดว่ากลุ่มของโพรเซสในคอนเทนเนอร์มีสิทธิ์ที่จะใช้งานทรัพยากรอะไรได้บ้างและเป็นปริมาณมากน้อยขนาดไหน

# เม้าท์เนมสเปซ

- แฟลก CLONE_NEWNS (เพราะเป็นอันแรก)
- เม้าพอยต์ ประกอบไปด้วย (1) เม้าท์ซอรส์ (อุปกรณ์/พาติชั่น) (2) พาทเนม และ(3) ไอดีของเม้าท์พาเรนท์
- มีความยืดหยุ่นกว่า chroot ซึ่งกำหนดให้โพรเซสใช้ได้เฉพาะสับทรี (subtree) ของไฟล์ซิสเต็ม แต่เม้าท์เนมสเปซอนุญาตให้เปลี่ยนแปลงได้มากกว่า
- เม้าท์เนมสเปซ อนุญาตให้ผู้ใช้สร้างภาพเสมือนของไฟล์ซิสเต็มของตนเองสำหรับกลุ่มของโพรเซส
- เม้าท์เนมสเปซ อนุญาตให้กลุ่มของโพรเซสหรือคอนเทนเนอร์มองเห็นเม้าท์พอยต์ (private mount) ที่เห็นเฉพาะโพรเซสภายในคอนเทนเนอร์และแยกจากคอนเทนเนอร์อื่น
  - เช่นแต่ละครเทนเนอร์มี /tmp ของตนเอง

# เม้าท์เนมสเปซ

- อนุญาตให้ผู้ใช้แชร์ (share) สับทรีของเม้าท์เนมสเปซหนึ่ง เรียกว่าการพรอบพาเกต (propagate) ไปยังเม้าท์เนมสเปซอื่นได้
- อนุญาตให้มีการพรอบพาเกต mount และ umount device จากเม้าเนมสเปซหนึ่งไปยังเม้าท์เนมสเปซอื่น
  - ต.ย. เช่น เม้า CD ในเม้าท์เนมสเปซหนึ่งแล้วพรอบพาเกตให้ทุกเม้าท์เนมสเปซ
- สามารถสร้างเม้าท์เนมสเปซพร้อมกับเนมสเปซอื่นเช่น พีไอดี ทำให้เกิด /proc/PID ขึ้นอย่างสอดคล้อง

# เม้าท์เนมสเปซ

- ก่อนลินุกซ์ 2.4.19 โพรเซสทุกโพรเซสใช้เม้าท์พอยต์ของระบบเดียวร่วมกัน และซิสเต็มคอลเกี่ยวกับพาทเนมทั้งหมด ทำงานกับชุดของเม้าท์พอยต์นั้น
- ปัจจุบัน ระบบลินุกซ์จะสร้างลิสต์ของเม้าท์เนมสเปซในระบบ
  - โพรเซสแต่ละโพรเซสจะต้องอยู่ในเม้าเนมสเปซอินสแตนซ์อันใดอันหนึ่ง
  - เมื่อโพรเซสสุดท้ายจบการใช้งานเม้าท์เนมสเปซ เม้าเนมสเปซจะถูกทำลาย

# ไอพีซีเนมสเปซ

- แฟลก CLONE_NEWIPC
- ไอพีซี (inter-process communication) ได้แก่
  - message queue
  - shared memory
  - semaphore
  - pipe เป็นต้น
- แยกไอพีซีออบเจกต์สำหรับกลุ่มของโพรเซส ออกจากของกลุ่มอื่น
- โพรเซสในกลุ่มไอพีซีเนมสเปซอินสแต๊นซ์เดียวกันจะเห็นไอพีซีออบเจกต์ของกลุ่ม แต่ไม่เห็นของเนมสเปซอื่น

# ไอพีซีเนมสเปซ

- ภายในแต่ละเนมสเปซอินสแตนซ์ โพรเซสจะเห็น
  - system V IPC ไอดี และ
  - /dev/mqueue และ
  - อินสแตนซ์ที่เกี่ยวข้องกับไอพีซีใน /proc
  - semaphore
- ไอพีซีออปเจกต์จะถูกทำลายเมื่อลบไอพีซีเนมสเปซ

# ซีกรุ๊ปเนมสเปซ

- แฟลก CLONE_NEWCGROUP
- กลุ่มของโพรเซสเห็น ซีกรุ๊ปเนมสเปซอินสแตนซ์เดียวกัน
- ทำความเข้าใจซีกรุ๊ป
- ภาพเสมือนของพาทเนมที่อยู่ใน /proc/PID

# เน็ตเวิร์คเนมสเปซ

- แฟลก CLONE_NEWNET
- แยกทรัพยากรที่เกี่ยวข้องกับเน็ตเวิร์ค เช่น ไอพีแอดเดรส และ เร้าติ้งเทเบิ้ล /proc/net /sys/class/net และ netfilter กฎ firewall และ socket port numbers และ UNIX domain sockets
- ทำให้คอนเทนเนอร์มีตัวตนในระบบเครือข่าย โดยสร้างภาพเสมือนที่ทำให้คอนเทนเนอร์เหมือนกับ
  - มีอุปกรณ์เชื่อมต่อกับระบบเครือข่ายของตนเอง
  - แอบพลิเคชันที่รันอยู่ในคอนเทนเนอร์มีชุดของพอร์ตของตนเอง ที่อาจซ้ำกันกับพอร์ตในคอนเทนเนอร์อื่นได้ ทำให้คอนเทนเนอร์สามารถสร้างเอ็นพอยต์สำหรับสื่อสารกับอินเตอร์เน็ต และสามารถสร้างคอนเนคชันกับคอนเทนเนอร์อื่นและคอมพิวเตอร์อื่นบนอินเตอร์เน็ตได้
  - เช่นรันเว็บเซริฟเวอร์บนพอร์ต 80 ของคอนเทนเนอร์

# เน็ตเวิร์คเนมสเปซ

- เครื่องโฮส สามารถสร้างเร้าติ้งเทเบิ้ลเพื่อเร้าเพคเก็ตไปยังอุปกรณ์เครือข่ายเสมือนของแต่ละคอนเทนเนอร์
- อุปกรณ์ veth (virtual ethernet) เป็นอุปกรณ์ที่ใช้สร้างการเชื่อมต่อระหว่างคอนเทนเนอร์กับเครื่องโฮส
- เราสามารถย้าย เน็ตเวิร์คอินเตอร์เฟส จาก เน็ตเวิร์คเนมสเปซหนึ่งไปยังเน็ตเวิร์คเนมสเปซอื่นได้
  - ip link set dev eth0 netns PID

# เน็ตเวิร์คเนมสเปซ

- เน็ตเวิร์คเนมสเปซทำให้คอนเทนเนอร์สามารถมีระบบเน็ตเวริคเสมือนของตนเองและทำตัวเป็นเซิร์ฟเวอร์ได้ และอาจใช้เป็นที่ทดสอบและจำลองการเชื่อมต่อที่ซับซ้อนได้ด้วย แทนที่จะใช้อุปกรณ์จริง
- การแยกช่วยเรื่องความปลอดภัย แยกโพรเซสจากเน็ตเวิร์ค
  - เริ่มต้นจากเนมสเปซที่ไม่มีอุปกรณ์ใด
  - ถ้าโพรเซสที่โดนแฮกอยู่ในเน็ตเวิร์คเนมสเปซก็จะไม่ส่งผลกระทบกับเน็ตเวิร์คโดยรวมทั้งหมด

# เน็ตเวิร์คเนมสเปซ

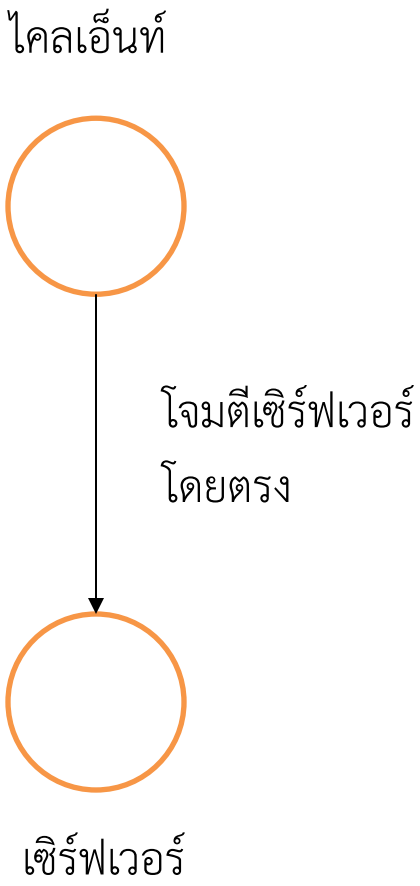

# เน็ตเวิร์คเนมสเปซ

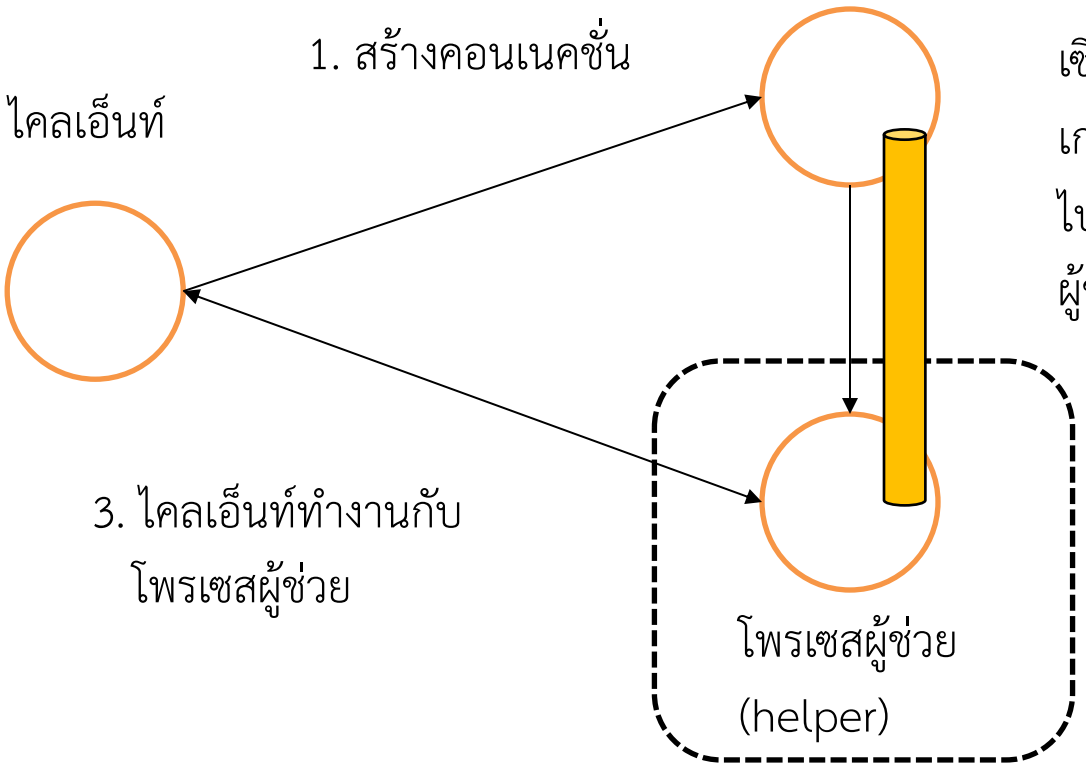


2. ส่งต่อคอนเนคชั่นให้โพรเซสผู้ช่วย วิธีการหนึ่งคือ ส่งซอกเกต ไฟล์เดสคริปเตอร์ของเซิร์ฟเวอร์ ผ่านยูนิกส์แมนซอกเกต (UNIX Domain Socket) ไปยังโพรเซสผู้ช่วยแล้วให้ผู้ช่วยติดต่อกับไคลเอ็นท์ [1]

เน็ตเวิร์คเนมสเปซอินสแตนซ์ไม่มีอุปกรณ์เน็ตเวิร์คใดข้างใน

[1] https://openforums.blog/2016/08/07/open-file-descriptor-passing-over-unix-domain-sockets/

# เน็ตเวิร์คเนมสเปซ ใน ด๊อกกอร์

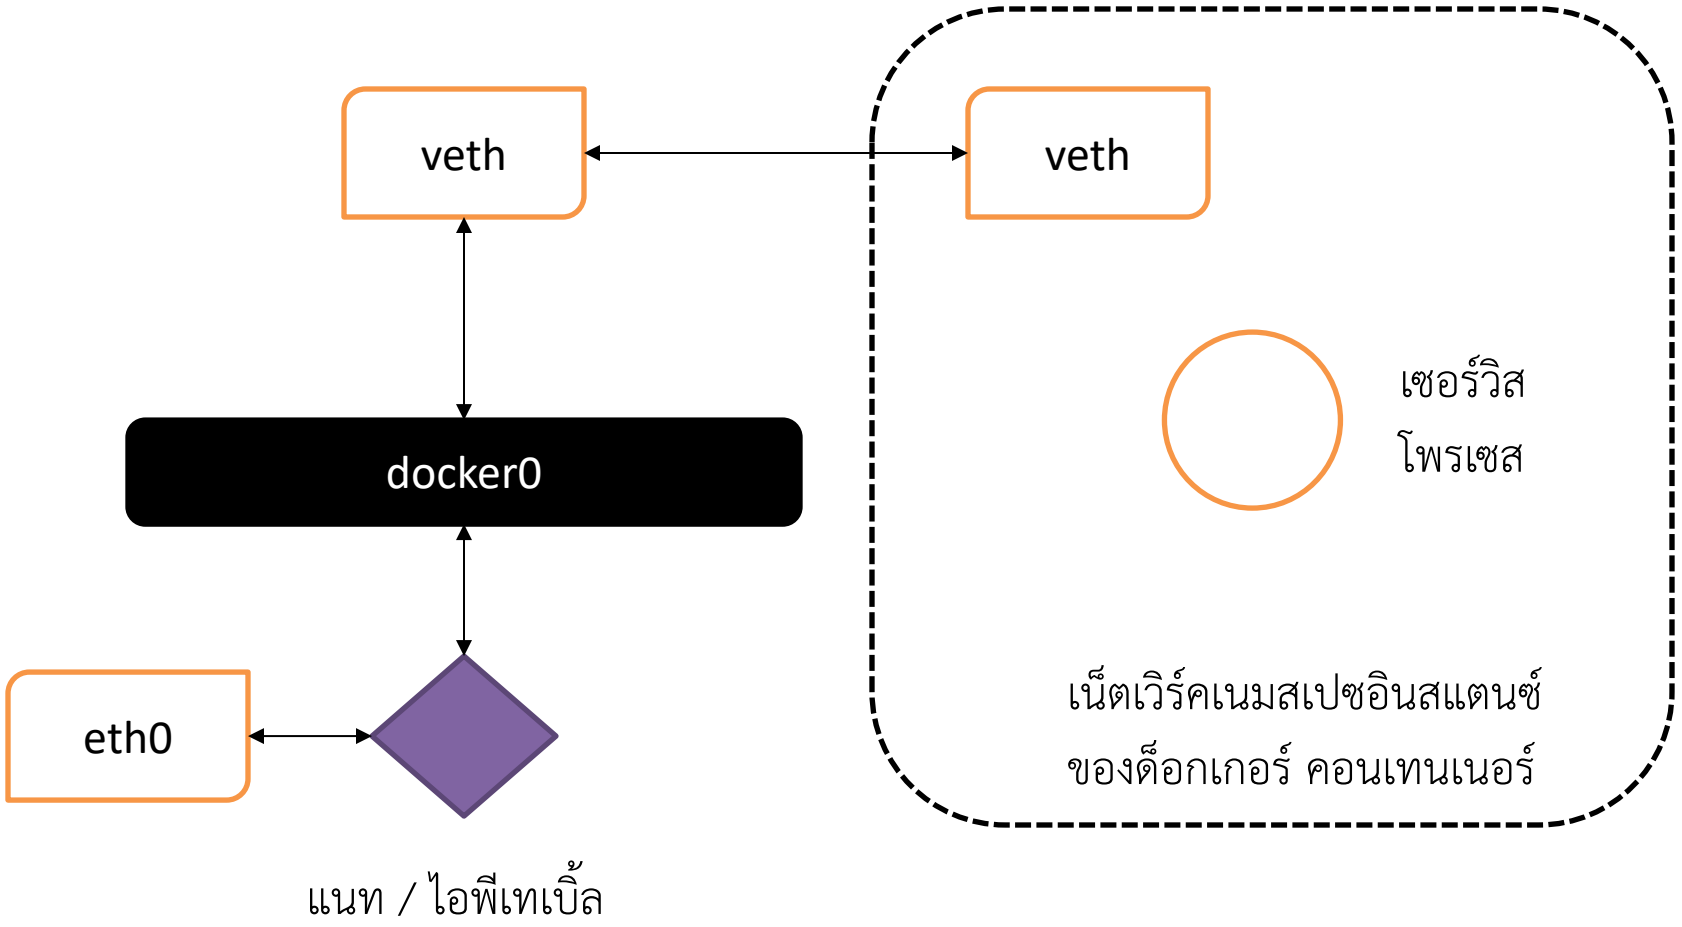


[2] https://www.youtube.com/watch?v=kl8roLaLy-g

# พีไอดีเนมสเปซ

- แฟลก CLONE_NEWPID
- แยกพีไอดีของโพรเซสในคอนเทนเนอร์ ทำให้สามารถไมเกรตคอนเทนเนอร์ไปรันบนโฮสเครื่องใหม่ได้ โดยไม่ต้องกลัวว่าพีไอดีจะซ้ำ
- ความสำพันธ์ระหว่างพีไอดีเนมสแปซอินสแตนซ์เป็นแบบแผนภาพต้นไม้ เริ่มต้นจากอินสแตนซ์เริ่มต้น
- พีไอดีเนมสเปซอนุญาตให้แต่ละพีไอดีเนมสเปซอินสแตนซ์มีโพรเซส init ซึ่งมีพีไอดี 1 และจะเป็นพาเรนท์ของโพรเซสที่เป็นลูกกำพร้าในพีไอดีเนมสเปซอินสแตนซ์ และเราสามารถใช้โพรเซสพีไอดี 1 เพื่อกำหนดค่าเริ่มต้น
- พาเรนพีไอดีอินสแตนซ์จะเห็นพีไอดีของโพรเซสทุกโพรเซสที่อยู่ในอินสแตนซ์ลูกและอินสแตนซ์ในทุกระดับที่เกิดจากมัน อินสแตนซ์ลูกจะไม่เห็นโพรเซสของอินสแต๊นซ์พ่อแม่
- พีไอดีอินสแตนซ์ในลินุกซ์มี 32 ระดับ

# พีไอดีเนมสเปซ

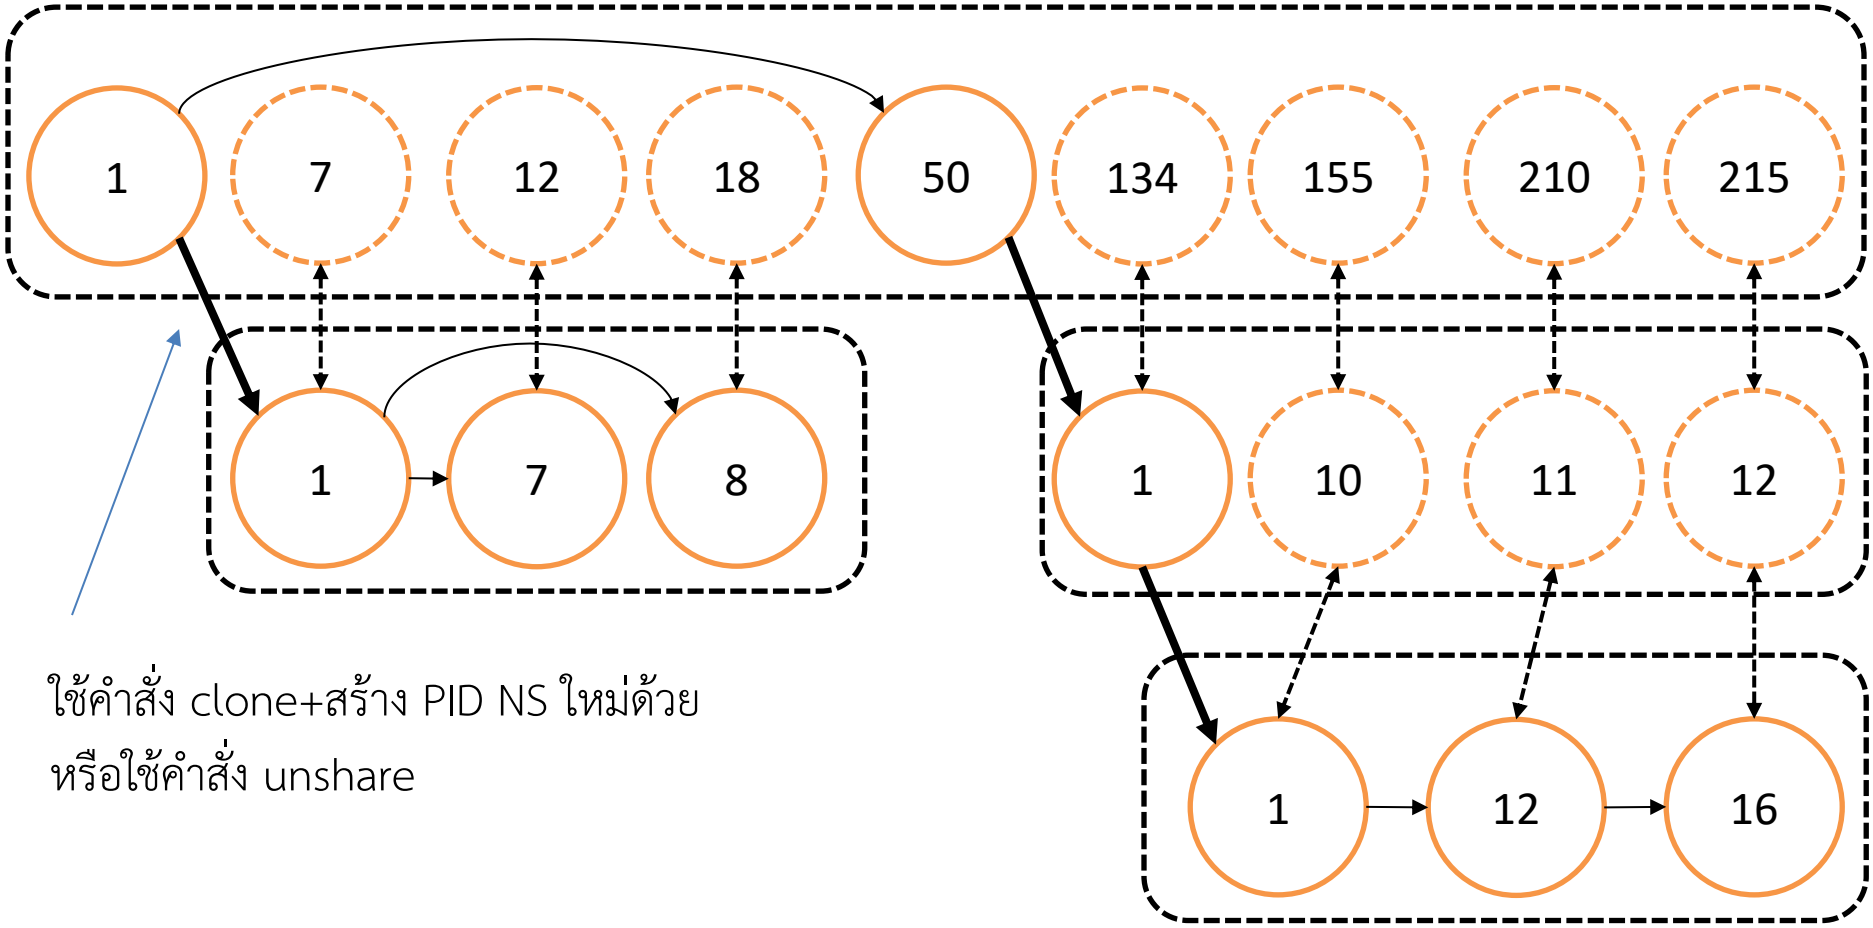


ใช้คำสั่ง clone+สร้าง PID NS ใหม่ด้วย

หรือใช้คำสั่ง unshare

# พีไอดีเนมสเปซ

- โพรเซสยังอยู่ในเนมสเปซอินสแตนซีเดียว แต่โพรเซสในเนมสเปซของบรรพบุรุษแค่เห็นพีไอดีที่เป็นตัวแทนของโพรเซสในพีไอดีอินสแตนซ์ระดับทายาทของมันเท่านั้น
  - ถ้าต้องการ พาเรนท์เนมสเปซจะห็น เทรดไอดีของโพรเซสที่มันมองเห็นได้โดยดูจาก /proc
- เมื่อเรียก getpid() ในพีไอดีเนมสเปซ จะได้ค่าพีไอดีในพีไอดีเนมสเปซที่โพรเซสนั้นอยู่
- ถ้าพีไอดี 1 ในพีไอดีเนมสเปซอินสแตนซ์เรียก getppid() จะได้ค่า 0 เพราะมองไม่เห็นพาเรนท์

# พีไอดีเนมสเปซ

- เพื่อให้พีไอดีเนมสเปซอินสแตนซ์ มี /proc/PID ที่ถูกต้องจะต้องสร้างเม้าท์เนมสเปซอินสแตนซ์ด้วย และ
- mount /proc สำหรับพีไอดีอินสแตนซ์นั้น จึงจะทำให้ได้ค่า /proc/PID ที่ถูกต้องซึ่งจำเป็นสำหรับซอฟต์แวร์เช่น ps และ top
- ถ้าโพรเซสที่มีพีไอดี 1 ใน พีไอดีเนมสเปซจบการทำงาน โพรเซสในพีไอดีเนมสเปซทั้งหมดจะจบการทำงานและ พีไอดีเนมสเปซอินสแตนซ์จะจบลง
- เหมาะกับการจบการประมวลผลของคอนเทนเนอร์

```
$ sudo unshare -p -f bash
root@flyvm:/srv/kasidit/study/namespace# echo $$
1
# ps
    PID TTY          TIME CMD
   3926 pts/1    00:00:00 sudo
   3927 pts/1    00:00:00 unshare
   3928 pts/1    00:00:00 bash
   3935 pts/1    00:00:00 ps
# ls /proc
1     1227  1406  247   2728  3055  3265  3649  46   830        execdomains  pagetypeinfo
10    123   1407  248   28    3061  3288  3659  463  831        fb           partitions
...
# less /proc/1/status
```

```
$ sudo unshare -p -m -f bash
#
# echo $$
1
# mount -t proc none /proc
# ls /proc
1          cpuinfo      fs          kmsg         modules       scsi          thread-self
9          crypto       interrupts  kpagecgroup  mounts        self          timer_list
...
# ps
    PID TTY          TIME CMD
      1 pts/1    00:00:00 bash
     10 pts/1    00:00:00 ps
# less /proc/1/status
```

# ยูเซอร์เนมสเปซ

- แฟลก CLONE_NEWUSER
- แยกผู้ใช้และกรุ๊ปไอดีของผู้ใช้
- ในลิสต์ข้อมูลของโพรเซส ค่า ยูไอดี (UID) และจีไอดี (GID) ของโพรเซสที่มองจากภายในยูเซอร์เนมสเปซ และจากภายนอกยูเซอร์เนมสเปซสามารถต่างกันได้
- ภายนอกยูเซอร์เนมสเปซอินสแตนซ์ โพรเซสมี ยูไอดีปกติ แต่ภายในยูเซอร์เนมสเปซอินสแตนซ์ ของโพรเซสนั้น โพรเซสอาจมียูไอดีเป็น 0 คือเป็น superuser สำหรับการประมวลผลภายในเนมสเปซ
- การสร้างยูเซอร์เนมสเปซอินสแตนซ์ไม่จำเป็นต้องใช้ sudo แต่พอสร้างแล้วโพรเซสในเนมสเปซสามารถรันเป็นรูทได้ (ภายในขอบเขตของเนมสเปซ)

# ยูเซอร์เนมสเปซ

- อนุญาตให้ผู้ใช้ แมป ช่วงของ UID ของกลุ่มของโพรเซสในยูเซอร์เนมสเปซ กับ UID ของเครื่องจริง เช่น
  - ในคอนเทนเนอร์ A UID 0 ถึง 999 จริงๆแล้วคือ UID 2000 ถึง 2999 บนเครื่องจริง
  - ในคอนเทนเนอร์ B UID 0 ถึง 999 จริงๆแล้วคือ UID 3000 ถึง 3999 บนเครื่องจริง
- ทำโพรเซสของ UID 0 ในคอนเทนเนอร์สามารถปฏิบัติงานเป็นรูทของคอนเทนเนอร์นั้นได้

# สรุป

- แนะนำ Namespaces
- ชนิดของ Namespaces
- แนะนำ Namespace แต่ละชนิดที่เกี่ยวข้องกับคอนเทนเนอร์
- ต่อไปเราจะแนะนำ ซีกรุ๊ป